



Retrieval Augmented Generation - Téorico

Curso: Deep Learning Avanzado
Unidad 3: Transformers

Luis Eduardo Ferro Diez 2024




Problemas con los modelos de lenguaje

- Modelos altamente complejos y pesados a nivel de cómputo.
- Requerimiento de hardware especializado significativamente costoso.
- La necesidad de datos y accesabilidad a los mismos es a veces inversamente proporcional.
- La calidad de los datos y el proceso de curación es también a veces inversamente



Arquitectura real de un modelo BERT, al rededor de 100 millones de parámetros.

Problemas con los modelos de lenguaje



- Diferentes tipos de ***alucinaciones***:
 - **Razonamiento**: Cuando las premisas no son coherentes o imprecisas.
 - **Memoria**: Cuando el modelo falla en generar información precisa basada en conocimiento previo.
- Carencia de fuentes de información para contrastar.
- Conocimiento estático.

Retrieval Augmented Generation - RAG




Figure 1: Overview of our approach. We combine a pre-trained retriever (*Query Encoder + Document Index*) with a pre-trained seq2seq model (*Generator*) and fine-tune end-to-end. For query x , we use Maximum Inner Product Search (MIPS) to find the top-K documents z_i . For final prediction y , we treat z as a latent variable and marginalize over seq2seq predictions given different documents.

RAG - Dense Passage Retrieval (DPR)





Figure 7-10. DPR's bi-encoder architecture for computing the relevance of a document and query

RAG



LLaMA
by Meta



Usuario

Genera un query


q

multilingual-e5-small

Codifica los documentos

d

**wiki
How**



Top K Documentos



Vector Store

$d(z)$

Contexto (q + top k)

Lorem ipsum dolor sit amet, consectetur
adipiscing elit, sed do eiusmod tempor
incididunt ut labore et dolore magna aliqua.

RAG Simple

